2

2-1

1. 分类

additive : $W(x, p+\Delta p)$ 叠加法更新

compositional : $W(W(x,\Delta p), p)$ 迭代法更新

forward

inverse

求问优化法：

G-N

Steepest Descent

Newton

L-M

	forward	inverse
additive	original L.K 法 (1981)	Hager - Belhumeur (1998)
compositional	shum. Szeliski 法 (2000)	Baker and Matthews (2001)

2. - $I(W(x,p))$ 是对图像作 wrap，它可以将 I 中坐标映射到 template T 的坐标系中。

- wrap 操作不仅仅出现在 compositional 中，在 additive 中也有。（为什么门这强调了 compositional）。

- wrap 本身是一种比如"平移变换"或"Affine 变换"（Affine 除了平移信息，还带有 scale / 旋转信息）。其 $W(x,p)$ 由参数 $p \in \mathbb{R}^n$ 决定。

- 我们 PPT 中会想求解 optical flow 的 $\frac{dx}{dt}$，$\frac{dy}{dt}$，即一些 pixel 的运动速度。

- 经过 wrap 后的图像更容易与 Template 重合，计算出的 dx/dt 与 dy/dt 更合理，克服了剧烈运动后的对齐误差。

3. 正向法中：$$\sum [I(W(W(x,\Delta p),p)) - T(x)]^2$$

反向法中 incremental warp $W(x,\Delta p)$ 在与当前 estimate 结合时先被 invert 了，即同时对"模板"与"输入图像"变换。

$$\longrightarrow \quad \sum [T(W(x,\Delta p)) - I(W(x,p))]$$

2.2.

1. 误差定义： $e = I_1(x,y) - I_2(x+dx, y+dy)$

2. $$\frac{\partial e}{\partial dx} = \underbrace{\frac{\partial e}{\partial I_2}\Bigg|_{\substack{x=x+dx\\ y=y+dy}}}_{-1} \cdot \underbrace{\frac{\partial I_2}{\partial u}\Bigg|_{u=x+dx}}_{\frac{I_2(x+1)-I_2(x-1)}{(x+1)-(x-1)}} \cdot \underbrace{\frac{\partial u}{\partial dx}}_{1}$$

$$\frac{\partial e}{\partial dy} = -1 \cdot \frac{I_2(y+1) - I_2(y-1)}{(y+1)-(y-1)}$$

2.4.

1. coarre-to-fine：先用低分辨率，得到的结果输入至高分辨率中

2.
- 光流法中，上层输出的 keypoint vecton 到下层中.
- 直接法中，上层输出"变换矩阵 T"到下层中.
- 特征点法中，(比如 SIFT) 是为了解决尺度不变性问题，为了匹配.

2.6 讨论

1. 有恒定不变假设，但有可能不满足。

   解决方法： zero-mean，考虑曝光时间

2. 差异不明显： 图像块↑，时间↑

3. 层数↑ 效果↑

   缩放倍率影响不大，若 scale 太小，则需更多层。